

Uniwersytet Jagielloński w Krakowie
Wydział Fizyki, Astronomii i Informatyki Stosowanej

Paweł Łabno

Nr albumu: 1138170

Implementacja Sztucznej Inteligencji dla gry *Wsiąść do Pociągu*

Praca magisterska
na kierunku Informatyka Stosowana

Praca wykonana pod kierunkiem
dr Przemysław Witaszczyk
Zakład Technologii Gier

Kraków 2018

Oświadczenie autora pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

.....
Kraków, dnia

.....
Podpis autora pracy

Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

.....
Kraków, dnia

.....
Podpis kierującego pracą

Spis treści

| | | |
|----------|---|-----------|
| 1 | Wprowadzenie | 4 |
| 1.1 | Wprowadzenie do pracy | 4 |
| 1.2 | Definicja pojęć | 4 |
| 1.3 | Zasady gry <i>Wsiąść do pociągu</i> | 5 |
| 2 | Przebieg badania | 8 |
| 2.1 | Analiza zachowań gracza | 8 |
| 2.2 | Model doświadczenia | 8 |
| 3 | Model algorytmiczny | 10 |
| 3.1 | Wprowadzenie do eksperymentu | 10 |
| 3.2 | Opis algorytmu | 10 |
| 3.3 | Wyniki modelu algorytmicznego | 15 |
| 3.4 | Podsumowanie | 15 |
| 4 | Model sieci neuronowej | 18 |
| 4.1 | Wprowadzenie do eksperymentu | 18 |
| 4.2 | Model danych wejściowych | 19 |
| 4.3 | Model danych wyjściowych | 20 |
| 4.4 | Struktura sieci | 20 |
| 4.5 | Proces weryfikacji uczenia | 20 |
| 4.6 | Zbiór danych uczących | 21 |
| 4.7 | Wyniki | 21 |
| 4.8 | Podsumowanie | 21 |
| 4.9 | Wnioski na temat uczenia | 23 |
| 5 | Optymalizacja wyników | 25 |
| 5.1 | Wprowadzenie do eksperymentu | 25 |
| 5.2 | Przebieg doświadczenia | 25 |
| 5.3 | Wyniki | 26 |
| 5.4 | Omówienie wyników | 26 |
| 5.5 | Podsumowanie | 28 |
| 6 | Dowód działania sieci | 29 |
| 6.1 | Wprowadzenie do eksperymentu | 29 |
| 6.2 | Model eksperymentu | 29 |

| | | |
|----------|---------------------------|-----------|
| 6.3 | Wyniki | 29 |
| 6.4 | Podsumowanie | 29 |
| 7 | Podsumowanie pracy | 32 |
| 8 | Słownik | 33 |
| 9 | Bibliografia | 35 |

Rozdział 1

Wprowadzenie

1.1 Wprowadzenie do pracy

Wraz z rozwojem możliwości technicznych komputerów człowiek szukał kolejnych zastosowań dla swojego wynalazku. Doskonałym celem do tego było sprawienie by życie człowieka stało się prostsze. Początkowo odbywało się to za pomocą przemyślanych i sprawdzonych algorytmów wykorzystywanych do celów naukowych oraz wojskowych. Pojawiały się jednocześnie coraz bardziej skomplikowane problemy, dla których przygotowanie działającego algorytmu w każdym przypadku stanowiło wyzwanie. Na ratunek posłużyły sieci neuronowe, które po zaprojektowaniu wymagały odpowiednio przygotowanych danych uczących.

Taka metoda pracy oraz podejmowania decyzji w ostatnich latach stawiała się coraz bardziej popularna i powszechnie wykorzystywana - np. w transporcie, finansach czy medycynie. Pojawiły się wreszcie próby wykorzystania sieci neuronowych w sytuacjach, dla których nie można z łatwością ocenić czy otrzymany wynik jest prawidłowy - przykładowo w grach.

W mojej pracy chcę przygotować implementację sztucznej inteligencji dla gry *Wsiąść do Pociągu* w oparciu o zaprojektowany algorytm oraz sztuczną sieć neuronową.

1.2 Definicja pojęć

W celu lepszego zrozumienia treści pracy warto przyswoić kilka pojęć przedstawionych poniżej. Kluczowe pojęcia, pojawiające się w treści pracy dotyczące samej gry znalazły się w Rozdziale 8.

Gra W literaturze pojawia się wiele definicji dla gry. Można uznać, że jest to czynność o rozrywkowym charakterze, w której uczestniczy jeden lub wielu graczy. Grę można również opisać jako model matematyczny charakteryzujący się określonymi zasadami oraz zbiorem możliwych operacji na tym modelu.

Teoria gier W przypadku kiedy w rozgrywce uczestniczy więcej niż jeden gracz możemy rozważać zachowania każdego z uczestników. Możemy również założyć, że każdy z graczy chce

uzyskać jak najbardziej korzystny dla siebie wynik.

Klasyfikacja gry Gra *Wsiąść do Pociągu* jest grą wieloosobową dopuszczającą od dwóch do pięciu graczy, niesymetryczną z niepełną informacją. Decyzje podejmowane są w sposób sekwencyjny po jednym ruchu na uczestnika rozgrywki.

Problem klasyfikacji W grze *Wsiąść do Pociągu* pojawia się problem decyzyjny w postaci klasyfikacji. Klasyfikacja jest problemem przyporządkowania danego zestawu danych do jednej lub więcej klas ze zbioru co najmniej dwóch klas. *Przeciwieństwo: Regresja*

Gra z niepełną informacją Określenie gra z niepełną informacją oznacza, że gracze podejmują swoje decyzje nie wiedząc o tym jakie cele mają inni uczestnicy rozgrywki. W grze *Wsiąść do pociągu* polega to m.in. na braku wiedzy jakie bilety (oraz czy zostały ukończone) realizują konkurenci.

Uczenie maszynowe Według Donald’a Michie:

System uczący się wykorzystuje zewnętrzne dane empiryczne w celu tworzenia i aktualizacji podstaw dla udoskonalonego działania na podobnych danych w przyszłości oraz wyrażania tych podstaw w zrozumiałej i symbolicznej postaci

Głębokie sieci neuronowe Głębokie sieci neuronowe są szczególnym przypadkiem uczenia maszynowego. Sieć składa się z więcej niż jednej warstwy ukrytej, a reprezentacja wewnętrzna neuronów niekoniecznie jest odwzorowaniem liniowym.

1.3 Zasady gry *Wsiąść do pociągu*

W celu zrozumienia pracy należy także zrozumieć zasady gry (model) *Wsiąść do Pociągu* będącej tematem badania. Pełna treść polskiej instrukcji do gry jest dostępna pod wpisem nr. 1 w bibliografii pracy.

1.3.1 Omówienie celu gry

Celem rozgrywki jest uzyskanie jak największej liczby punktów. Gracz może zdobyć punkty za zarezerwowanie połączeń (Tablica 1.1) oraz za ukończenie biletów (korzystając z połączeń jednego gracza można dotrzeć z jednego wskazanego miasta do drugiego).

1.3.2 Faza przygotowania rozgrywki

Po rozłożeniu planszy następuje przygotowanie zasobów do gry:

1. Przygotowanie talii

Gracze tasują dostępne karty wagonów oraz biletów. Rozkładają na planszy pierwszych 5 kart wagonów - widocznych awersiem dla graczy. Jeśli są wśród nich co najmniej 3 lokomotywy należy wymienić cały zestaw kart.

| Długość połączenia (w wagonach) | Ilość punktów |
|---------------------------------|---------------|
| 1 | 1 |
| 2 | 2 |
| 3 | 4 |
| 4 | 7 |
| 5 | 10 |
| 6 | 15 |

Tablica 1.1: Ilość punktów otrzymywanych za zrealizowanie połączenia

2. Losowanie biletów

Każdy z graczy pobiera z talii biletów po trzy karty. Następnie wybiera które z nich zachować a które odłożyć na spód talii. Musi zachować conajmniej dwa bilety. *Jako bezpieczną taktykę gry przyjmuje się zachowanie jedynie dwóch kart biletów*

3. Losowanie kart wagonów

Każdy z graczy pobiera z talii biletów po cztery karty. Nie ma prawa ich odrzucić lub zamienić.

Gdy zostaną wykonane powyższe kroki uczestnicy gry mogą rozpocząć rozgrywkę.

1.3.3 Rodzaje decyzji podejmowanych przez gracza

W trakcie swojej tury gracz może wybrać jedną z trzech dostępnych akcji:

Rezerwacja połączenia

Warunki rezerwacji połączenia:

1. Gracz musi posiadać odpowiednią ilość kart wagonów odpowiedniego koloru (lokomotywa zastępuje dowolny kolor).
2. Gracz musi posiadać co najmniej tyle wolnych wagonów ile wynosi długość połączenia które chce zarezerwować.
3. Gracz nie zarezerwował ścieżki (w przypadku połączeń podwójnych) w połączeniu.
4. Pozostaje co najmniej jedna ścieżka wolna w połączeniu.
5. Połączenie ma dwie ścieżki, jedna z nich jest zajęta, druga wolna. W rozgrywce uczestniczy co najmniej 4 graczy.

Decyzja zabroniona:

Gracz nie posiada wagonów lub kart wagonów potrzebnych do zarezerwowania dowolnego połączenia na mapie.

Dobranie kart wagonów

Warunki dobrania kart wagonów:

1. Gracz może zdecydować o dobraniu do dwóch wagonów w zależności od tego jakie wagony chce dobrać.
2. Gracz może zabrać jako pierwszy wagon - kartę lokomotywy (Joker) z puli planszy. Nie dobiera wtedy drugiego wagonu.
3. Gracz może zabrać z talii lub puli dwie karty. Może być jedna karta z talii oraz jedna karta z planszy.

Decyzja zabroniona:

Skończyła się talia kart wagonów, na planszy nie znajdują się żadne kart wagonów a stos kart odrzuconych jest pusty.

Dobranie kart biletów

Gracz w ramach decyzji o dobranie biletów losuje 3 bilety z talii i decyduje, które zachowa, a które odrzuci. Zachować musi co najmniej 1 bilet.

Decyzja zabroniona:

W talii kart biletów nie pozostał żaden bilet.

1.3.4 Uzupełnianie kart wagonów na planszy

Gdy jeden z graczy dobierze kartę wagonów znajdującą się na planszy na jej miejsce pojawia się pierwsza karta z talii. Jeżeli w dowolnym momencie rozgrywki na planszy znajdują się co najmniej trzy karty lokomotyw to cały zestaw kart zostaje odrzucony, a na ich miejsce dobierane jest pięć kart z talii kart wagonów.

Jeżeli w danym momencie talia kart wagonów jest pusta należy potasować stos kart odrzuconych a następnie położyć go na miejscu talii kart wagonów. Jeżeli odbywa się to w trakcie uzupełniania kart na planszy to karty należy wykorzystać do uzupełnienia kart wagonów na planszy.

1.3.5 Koniec gry

Rozgrywka kończy się w momencie, gdy jednemu z graczy pozostają co najwyżej dwa wagoniki. Po tym zdarzeniu każdy z graczy ma jeszcze jeden ruch do wykonania. Gdy wszyscy gracze wykonają swój ostatni ruch przechodzi się do fazy podliczenia punktów.

Podliczenie przebiega następująco:

1. Podliczenie punktów za połączenia (według Tablicy 1.1)
2. Dodanie punktów za każdy zrealizowany bilet (według oznaczenia na bilecie)
3. Odjęcie punktów za każdy niezrealizowany bilet (według oznaczenia na bilecie)

Dla usprawnienia procesu gry w eksperymentach pominięto zasadę bonusowych 10 punktów dla gracza posiadającego najdłuższą nieprzerwaną ścieżkę

Rozdział 2

Przebieg badania

2.1 Analiza zachowań gracza

Pierwszym etapem pracy nad sztuczną inteligencją zostało przeanalizowanie zachowań graczy w celu przygotowania algorytmu, który wykorzystano do przygotowania zbioru uczącego. Jako rozsądne kroki w celu przeprowadzenia analizy przyjąłem:

1. Analiza rozgrywek z rzeczywistym graczem
2. Analiza rozgrywek z graczem komputerowym (dostępnym z grą w wersji cyfrowej).
3. Przeszukanie sieci internet w tematyce SI. Odnosnik wskazany w bibliografii.

Jako kluczowe w dalszej analizie przyjąłem następujące zachowanie gracza komputerowego:

1. Gracz kieruje rozgrywkę dla siebie - zależy mu jedynie na jak największej ilości punktów (w danym momencie oraz ogólnie).
2. Gracze nie przeszkadzają sobie nawzajem (uczestnicy rozgrywki nie podejmują decyzji mających na celu utrudnienie gry innym uczestnikom, wykluczając sytuację, gdy dla danego gracza decyzja blokująca jest jednocześnie najbardziej korzystną w kontekście zdobyczy punktowej).
3. Uczestnicy starają się najpierw ukończyć posiadane bilety a następnie gromadzą punkty.

2.2 Model doświadczenia

Po określeniu wstępnych założeń dotyczących sztucznej inteligencji przystąpiłem do przygotowania doświadczenia badającego jakość algorytmu oraz uczenia sieci za pomocą wygenerowanych danych. W pierwszym kroku określiłem mierniki, jakie posłużą mi do oceny sztucznej inteligencji, następnie wpisane zostały do Tablicy 2.1.

Dla uzyskania miarodajnych wyników dla każdej próby postanowiłem przeprowadzić tysiąc rozgrywek w każdym z modeli według konfiguracji zawartej w Tablicy 2.2.

| Parametr | Opis |
|--------------|--|
| MAX | Maksymalna liczba punktów zdobyta przez gracza |
| MIN | Najmniejsza liczba punktów zdobyta przez gracza |
| AVG | Sredni wynik punktowy |
| MED | Mediana punktów |
| AVG DONE TCK | Srednia liczba zrealizowanych biletów |
| AVG FAIL TCK | Srednia liczba niezrealizowanych biletów |
| 110 (%) | Liczba graczy z co najmniej 110 punktami |
| 120 (%) | Liczba graczy z co najmniej 120 punktami |
| 140 (%) | Liczba graczy z co najmniej 140 punktami |
| FAIL (%) | Liczba gier w których gracz dokonał ruchu zabronionego |

Tablica 2.1: Parametry rozgrywki

| Liczba graczy | Liczba rozgrywek |
|---------------|------------------|
| 2 | 250 |
| 3 | 250 |
| 4 | 250 |
| 5 | 250 |

Tablica 2.2: Konfiguracja danych testowych

W trakcie pracy dodałem dwa eksperymenty do doświadczenia - weryfikacja procesu uczenia oraz jakość działania sieci w zależności od przygotowanego modelu danych. Każde z tych badań odbywało się na mniejszej próbce składającej się z 60 rozgrywek dla każdej ilości graczy (sumarycznie 240 rozgrywek na próbkę).

Rozdział 3

Model algorytmiczny

3.1 Wprowadzenie do eksperymentu

Celem drugiej części eksperymentu był dowód, że komputer może rozgrywać samodzielnie partię gier *Wsiąść do Pociągu*. Wykorzystanie modelu algorytmicznego pozwoli uprościć zbieranie danych, które w opracowanej formie posłużą jako zbiór danych uczących. Opracowanie danych ma posłużyć również do ustalenia jakościowych wyników algorytmu, które posłużą do oceny jakości uczenia. W dalszej pracy model algorytmiczny będzie opisywany jako *Algorytm* lub *Algorytm klasyczny*.

3.2 Opis algorytmu

W pracy przygotowano kilka szczegółowych algorytmów:

Decyzja ogólna Jedna z trzech dozwolonych przez zasady gry decyzji (plus pominięcie tury w szczególnych przypadkach).

Decyzja bilet Decyzja polegająca na wyborze najlepszego podzbioru biletów z przekazanych jako parametr algorytmu.

Karta wagonów Decyzja polegająca na wyborze, które karty wagonów gracz powinien zabrać z planszy.

Rezerwacja połączenia Decyzja, której efektem jest wybór połączenia, które powinno zostać zarezerwowane przez gracza w pierwszej kolejności.

Przygotowanie tury Wyznaczenie kierunku w którym powinien się gracz poruszać w tym wyznaczenie dostępnych i brakujących połączeń.

Dodatkowo, grę można przedstawić jako graf przez co często pojawiają się ścieżki pomiędzy miastami - w tym celu zaimplementowano algorytm określający najkrótszą ścieżkę między

miastami w kontekście gracza uznając koszt dla zarezerwowanych przez gracza połączeń jako zero. Połączenia, które zostały już zarezerwowane przez innych graczy oznaczone zostały jako o bardzo dużym koszcie.

3.2.1 Decyzja ogólna

Wykorzystany w pracy algorytm przedstawiono na Rysunku 3.1 w formie schematu blokowego.

3.2.2 Poddecyzja - bilet

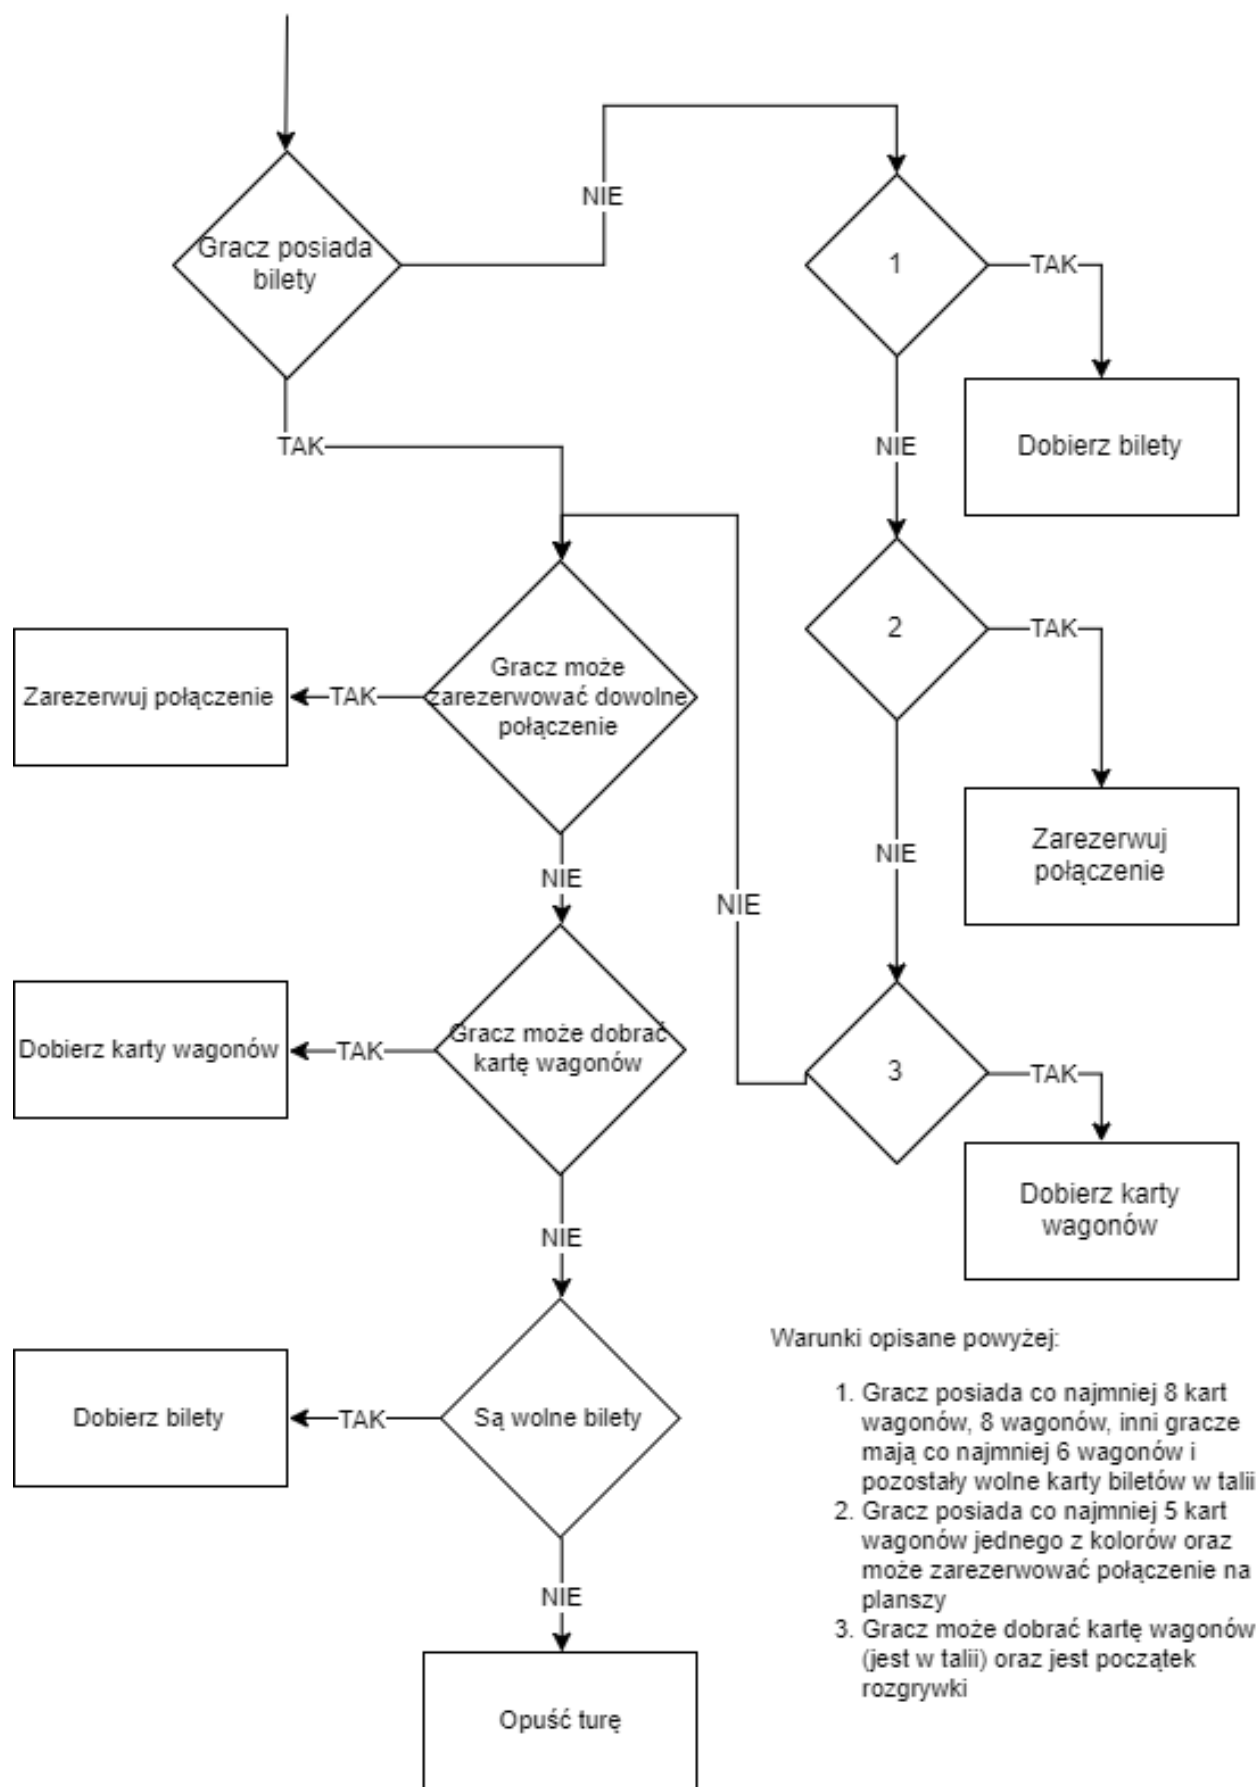
Wykorzystany w pracy algorytm wyboru biletów przedstawiono na Rysunku 3.2 w formie schematu blokowego.

3.2.3 Poddecyzja - karta wagonów

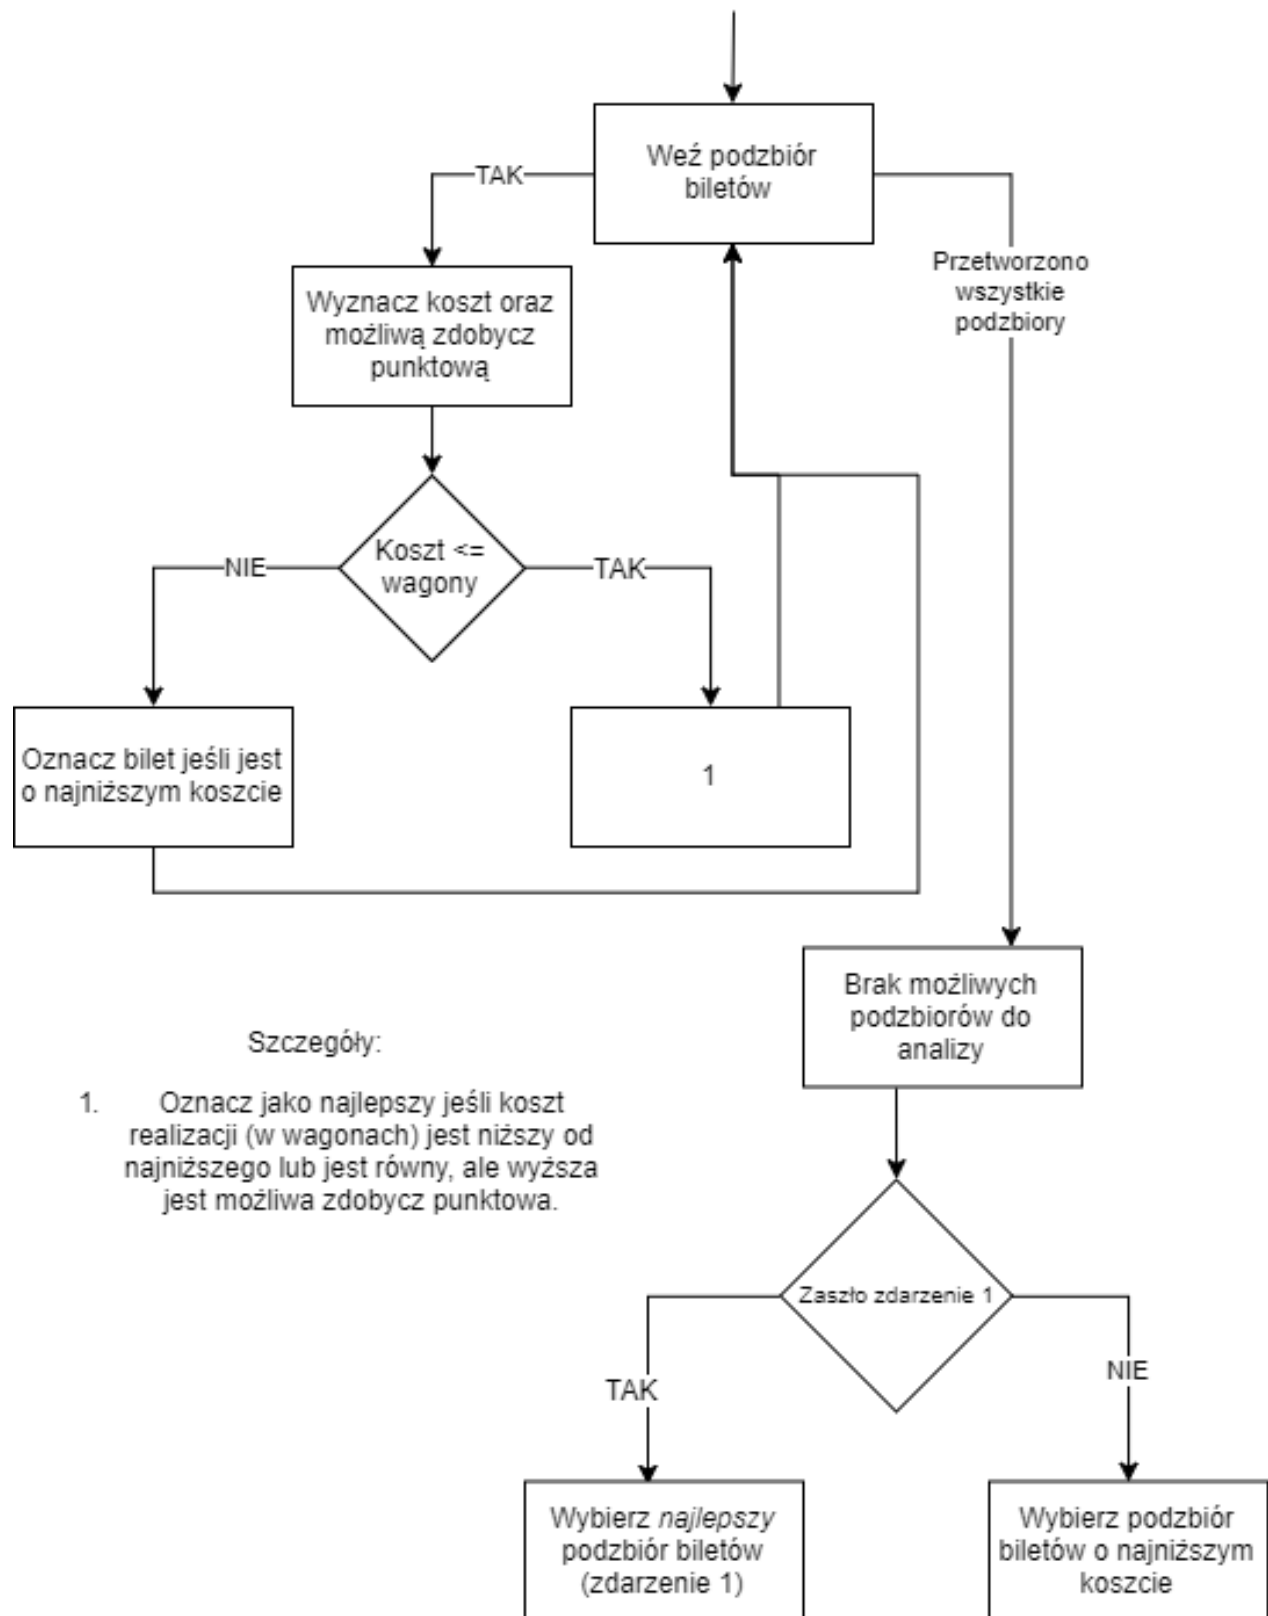
1. Policz dostępne karty wagonów na planszy (według kolorów) oraz ile kart każdego z kolorów potrzeba na zrealizowanie pozostałych biletów
2. Wyznacz kolory, których brakuje graczowi a następnie kolor, którego wagonów graczowi brakuje najwięcej.
3. Jeśli gracz ma zrealizowane wszystkie bilety - wez kartę z talii
4. Jeśli gracz ma zrealizowane wszystkie bilety, a talia się skończyła - wez losową kartę z planszy
5. Jeśli graczowi brakuje więcej niż 3 różnych kolorów kart - wez z talii
6. Jeśli potrzeba mniej niż 4 karty, a pozadany kolor jest na planszy - wez wybraną kartę z planszy
7. Jeśli pozostała jedna karta do zrealizowania biletu, gracz nie wybrał jeszcze w turze karty oraz jest karta *Lokomotywy* na planszy - wez wybraną kartę lokomotywy
8. Jeśli talia nie jest pusta - wez kartę z talii
9. Wez losową kartę z planszy

3.2.4 Decyzja - rezerwacja połączenia

1. Oblicz posiadane karty każdego z kolorów, oraz jakie karty są potrzebne do rezerwacji połączeń z biletów
2. Jeśli są karty w zbiorze *Pasujące* oznacz ten zbiór jako przetwarzany. W przeciwnym przypadku oznacz zbiór kart *możliwych*



Rysunek 3.1: Schemat blokowy algorytmu podejmującego decyzje o typie wykonywanego ruchu



Rysunek 3.2: Schemat blokowy algorytmu podejmującego decyzje o wyborze najlepszego podzbioru biletów

3. Jako kryterium wyboru połączenia do rezerwacji wybierz

Dla realizacji w przypadku niepustego zbioru *pasujace* wybierz najkrotsze polaczenie

W kazdym innym przypadku wybierz polaczenie gwarantujace najwiecej punktow.

4. Okresl pule kolorow do wykorzystania. Jesli jest wiecej niz jeden mozliwy kolor (w przypadku np. teczy), wybierz ten ktorego masz najwiecej kart
5. Wybierz karty wagonow podanego koloru

3.2.5 Przygotowanie tury

1. Okresl pule wszystkich polaczen potrzebnych do realizacji biletow gracza (okreslane jako *cel*)
2. Z wszystkich polaczen na mapie wyznacz te ktore gracz moze zrealizowac w danej turze (okreslane jako *mozliwosci*)

Dodaj polaczenia zawierajace sie w *celu*

Dodaj wszystkie polaczenia o dlugosci co najmniej 5

Dodaj wszystkie polaczenia gdy dlugosc zbioru *cel* jest rowna 0


3. Dla wszystkich polaczen ze zbioru *cel* (ktore gracz moze w ogole zarezerwowac)
Zawierajace sie w zbiorze *mozliwosci* dodaj do zbioru *pasujace*
W przeciwnym przypadku dodaj do zbioru *Brakujace*

3.2.6 Wyznaczanie tras do realizacji biletów

Planszę rozgrywki można przedstawić w formie modelu grafu, gdzie połączeniami są krawędzie a wierzchołkami miasta. Do wyznaczenia najbardziej korzystanego połączenia tras wykorzystano Algorytm Bellmana-Forda (wg. *Wprowadzenia do Algorytmów* - Bibliografia 4.). Algorytm ten pozwala nam na określenie całej najkrótszej ścieżki rozpoczynając od wierzchołka początkowego. Jako metodę porównywawczą dla kosztu ścieżki uznano:

1. Dla różnych kosztów (w wagonów) od węzła początkowego wybieramy ten który jest mniejszy.
2. Dla równego kosztu (w wagonach) od węzła początkowego wybieramy tą ścieżkę dla której ścieżka gwarantuje większą ilość punktów.

Przy osiągalnym koszcie realizacji biletów tj. koszt jest mniejszy od liczby wagoników gracza ścieżka o najniższym koszcie jest oznaczona jako cel realizacji. Wskazanie jest realizowane każdorazowo na początku tury gracza.



Rysunek 3.3: Rozkład punktacji wg. ilości graczy

3.3 Wyniki modelu algorytmicznego


W trakcie doświadczenia uruchomiono serie gier według konfiguracji opisanej w Tablicy 2.2. Wyniki uzyskane w doświadczeniu przedstawiono w Tablicy 3.1.

| Cecha | 2 graczy | 3 graczy | 4 graczy | 5 graczy | ogólnie |
|------------------------|----------|----------|----------|----------|---------|
| Minimum | 37 | 14 | 43 | 34 | 14 |
| Maksimum | 173 | 149 | 182 | 162 | 182 |
| Srednia | 107,02 | 98,02 | 98,03 | 94,59 | 98,16 |
| Mediana | 108 | 95 | 98 | 96 | 99 |
| (%) > 110 | 44,60 | 38,00 | 28,00 | 21,60 | 27,51 |
| (%) > 120 | 23,40 | 8,80 | 13,20 | 8,80 | 12,14 |
| (%) > 140 | 3,80 | 0,40 | 0,70 | 0,96 | 1,17 |
| Zrealizowane bilety | 3,63 | 3,01 | 3,21 | 2,8 | 3,08 |
| Niezrealizowane bilety | 0,46 | 0,58 | 0,56 | 0,62 | 0,57 |


Tablica 3.1: Wyniki uzależnione od ilości graczy

3.4 Podsumowanie

Podsumowując otrzymane dane możemy dojść do kilku wniosków, przede wszystkim, że decyzje podejmowane przez gracza komputerowego sprawiają wrażenie podejmowanych przez rze-



Rysunek 3.4: Globalny rozkład punktów



Rysunek 3.5: Wyniki wg. ilości graczy

czywistego gracza. Niestety gracz algorytmiczny ma swoje słabe oraz mocne strony co powoduje, że wykres częstości wartości punktów na koniec rozgrywki przypomina rozkład Gaussa.

Zgodnie z wynikami wskazanymi w Tablicy 3.1 możemy zauważyć, że przewidywany wynik gracza powinien wynieść ok. 98 punktów (wynosi tyle średni wynik punktowy oraz mediana). Obserwację potwierdza przebieg wykresu z Rysunku 3.4. Z zapisów rozgrywek wyczytać można również modę zdobyczy punktowej wynoszącą 106. Można ponadto zauważyć, że spora część rozgrywek kończy się wynikiem powyżej 87 punktów. Powyżej wyniku 140 punktów znajduje się znikoma część graczy - według tablicy zaledwie 1,17%.

Wnioski możemy również wynieść z Rysunku 3.3, który wskazuje rozkład punktów w zależności od ilości graczy. Zgodnie z oczekiwaniami przebieg każdego z wykresu przedstawia rozkład Gaussa. Najlepsze wyniki osiągają gracze uczestniczący w rozgrywce dwuosobowej. Jest to spowodowane powolnym zapełnianiem planszy przez co zdobywają mniejszą ilość punktów karnych za niezrealizowane bilety, jednocześnie gracz jest mniej karany za spóźniony ruch. W przypadku takiej konfiguracji można oczekiwać wyniku ok. 107 punktów.

Bardziej zbliżone do siebie są rozgrywki trzy- oraz cztero-osobowe, dla których średni wynik wynosi 98 pkt. Można zauważyć, że dla rozgrywek trzyosobowych po osiągnięciu maksimum częstości, częstość występowania wyników o danej ilości punktów maleje szybciej od rozgrywek czteroosobowych. Skutkiem tego jest znacznie wyższy procent graczy z wynikiem końcowym ponad 120 oraz ponad 140 punktów, co przedstawiono w Tablicy 3.1.

Kolejnym zauważalnym wnioskiem są lepsze wyniki dla rozgrywek 2 oraz 4 osobowych niż 3 oraz 5 graczy. Można to zauważyć na Rysunku 3.5, gdzie w przypadku średniej oraz mediany jest zauważalny trend malejący wyniku względem ilości graczy. Jako przyczynę tej sytuacji można wskazać szybsze zapełnianie się planszy. Można zaobserwować również niską średnią ilość niezrealizowanych biletów - można wnioskować, że co najmniej co drugi gracz zrealizował wszystkie swoje bilety. W kwestii zrealizowanych biletów ogólna średnia powyżej 3 biletów świadczy, że gracze zazwyczaj dociągali karty biletów.

Wysoka amplituda wyników jest spowodowana dużym spektrum możliwych stanów planszy (rezerwacji połączeń, biletów oraz celów graczy), przez co możliwe są wyniki bardzo dobre (powyżej 140 punktów) jak i złe (poniżej 60).

Rozdział 4

Model sieci neuronowej

4.1 Wprowadzenie do eksperymentu

Z łatwością można wskazać działanie przygotowanego algorytmu, gorzej jest w przypadku sieci neuronowej. Sieci neuronowe w swojej charakterystyce mogą być nieprzewidywalne, a duże znaczenie w jej efektywności odgrywa odpowiednie przygotowanie modelu danych, następnie struktury sieci a w końcu są potrzebne odpowiednie dane, które pozwolą sieć wyuczyć.

Przygotowanie sztucznej inteligencji opartej o uczenie maszynowe dla tego typu zagadnień wydaje się ciekawym podejściem. W większości gier uczestnik rozgrywki ma okrojony zakres dozwolonych w danym momencie typów decyzji (w algebrze *klas równoważności*). Przygotowanie klasyfikatora, którego celem będzie określenie jaka jest najlepsza w danym momencie decyzja jest realizowalne przez klasyfikator działający na podstawie uczenia maszynowego (np. DNNClassifier z biblioteki *tensorflow*). Przygotowanie algorytmu, który wybierze odpowiednią decyzję niesie za sobą ryzyko w postaci znacznej rozbudowy algorytmu o dodatkowe rozgałęzienia i ujęcie licznych przypadków szczególnych lub ograniczenie się do dobrego działania w okrojonym zakresie przypadków. Przygotowanie sieci neuronowej może pozwolić na obsługę zdarzeń szczególnych - zwłaszcza w przypadku, gdy takie zdarzenie znajdzie się w zbiorze danych uczących.

W przypadku gier planszowych, przygotowanie modelu danych nie jest niewykonalnym zadaniem, gdyż sama rozgrywka odbywa się w postaci unormowanej - większość zdarzeń oraz stanów możemy przedstawić w matematycznej formie (jak wskazano w Rozdziale 1.2) - jako wartości zmienne. W pierwszym kroku pracy nad siecią neuronową należało zbudować taki model danych w oparciu o *Stan gry*, na podstawie którego sieć będzie mogła podjąć jednoznaczną decyzję. Model danych powinien być pozbawiony szumu w postaci zbędnych danych.

Po przygotowaniu modelu przystąpiono do przygotowania danych uczących w oparciu o model algorytmiczny. Ostatnim krokiem przed rozpoczęciem procesu uczenia sieci było przygotowanie konfiguracji sieci, która będzie osiągać najlepsze wyniki w symulowanych rozgrywkach.

4.2 Model danych wejściowych

Model danych wejściowych przedstawiono w Tablicy 4.1. W trakcie przygotowania kierowałem się danymi jakie są wykorzystywane w trakcie wyboru decyzji w algorytmie *klasycznym*

| Nazwa | Typ | Zakres | Opis |
|----------------------------------|-----|-----------|---|
| Tura | Int | 0-100 | Aktualna tura gracza |
| Karty wagonów | Int | 0-120 | Suma kart wagonów gracza (wszystkich kolorów) |
| Wagony na planszy | Int | 0-5 | Ilość wagonów na planszy |
| Wagony w talii | Int | 0-120 | Ilość wagonów w talii |
| Wagony odrzucone | Int | 0-120 | Ilość odrzuconych wagonów |
| Bilety gracza | Int | 0-30 | Ilość biletów posiadanych przez gracza |
| Bilety w talii | Int | 0-30 | Ilość biletów pozostających w talii <i>biletów</i> |
| Wagony gracza | Int | 0-45 | Ilość wagoników posiadanych przez gracza |
| Punkty gracza | Int | -50 - 200 | Ilość punktów posiadanych przez gracza |
| Pozostałe karty wagonów | Int | 0 - 120 | Ilość kart wagonów w talii oraz na planszy |
| Liczba połączeń do zrealizowania | Int | 0 - 40 | Ilość połączeń na planszy, które gracz może zarezerwować |
| Liczba połączeń pasujących | Int | 0 - 40 | Ilość połączeń, które gracz może zrealizować z trasy biletów. |
| Liczba połączeń celowych | Int | 0 - 40 | Ilość połączeń na trasie biletów. |
| Liczba połączeń brakujących | Int | 0 - 40 | Ilość połączeń jakie brakuje graczowi do zrealizowania wszystkich biletów |
| Liczba graczy | Int | 2-5 | Ilość graczy w rozgrywce |
| Min wagonów | Int | 0 - 45 | Najmniejsza liczba wagonów wśród pozostałych graczy |
| Max wagonów | Int | 0 - 45 | Największa liczba wagonów wśród pozostałych graczy |
| Średnia wagonów | Int | 0 - 45 | Średnia liczba wagonów wśród pozostałych graczy |
| Mediana Wagonów | Int | 0 - 45 | Mediana liczby wagonów wśród pozostałych graczy |
| Min biletów | Int | 0 - 45 | Najmniejsza posiadanych liczba biletów wśród pozostałych graczy |
| Max biletów | Int | 0 - 45 | Największa posiadanych liczba biletów wśród pozostałych graczy |

| | | | |
|------------------------|-----|--------|--|
| Średnia biletów | Int | 0 - 45 | Średnia liczba posiadanych biletów wśród pozostałych graczy |
| Mediana biletów | Int | 0 - 45 | Mediana liczba posiadanych biletów wśród pozostałych graczy |
| Niezrealizowane bilety | Int | 0 - 30 | Liczba biletów <i>niezrealizowanych</i> przez aktywnego gracza |
| Zrealizowane bilety | Int | 0 - 30 | Liczba biletów <i>zrealizowanych</i> przez aktywnego gracza |
| Aktualny wynik gracza | Int | 0 - 30 | Liczba punktów bez liczenia punktów za bilety |

Tablica 4.1: Dane wejściowe sieci neuronowej

4.3 Model danych wyjściowych

W eksperymencie wykorzystano klasyfikator, który operuje na czterech możliwych klasach wyjściowych (do podglądu w 4.2):

| # | Nazwa | Opis decyzji |
|---|---------------------------|--|
| 0 | Opuszczenie tury | Gracz nie może podjąć żadnej decyzji |
| 1 | Pobranie karty wagonów | Gracz powinien pobrać karty tego typu (akumulacja zasobów) |
| 2 | Pobranie karty biletów | Gracz powinien pobrać karty tego typu (dobranie celów) |
| 3 | Zarezerwowanie połączenia | Gracz powinien zabezpieczyć punkty |

Tablica 4.2: Klasy określone przez klasyfikator

4.4 Struktura sieci

W pracy wykorzystano klasyfikator oparty o pracę głębokich sieci neuronowych. Warstwa wejściowa składała się z 26 charakterystyk. Następnie były dwie warstwy ukryte, które składały się odpowiednio z 160 oraz 120 neuronów. Na wyjściu klasyfikacja opierała się na 5 neuronach.

4.5 Proces weryfikacji uczenia

W trakcie zbierania pomiarów kilkakrotnie zmieniano model danych. Sieć podejmowała często zabronione decyzje spowodowane wpływem niepotrzebnych *charakterystyk*. W związku z tym usunięto dane o poczynaniach innych graczy (np. liczbie kart wagonów), a dodano informację o ilości różnych kolorów kart wagonów posiadanych przez gracza oraz największą ilość kart tego samego koloru.

Drugą ważną zmianą w modelu sieci neuronowej była redukcja ilości dozwolonych decyzji (klas). Początkowo jako punkt wejściowy był zapisany stan *start*, lecz ostatecznie został on usunięty. Obecność stanu była związana z początkowym założeniem wykorzystania rekurencyjnych sieci neuronowych.

4.6 Zbiór danych uczących

Jak kilkakrotnie wspomniano w pracy jako źródło danych uczących wykorzystano uruchomienie modelu algorytmicznego i zapis rozgrywek do pliku. Z powodu dużej amplitudy wyników zdecydowałem się na redukcję zbioru uczącego do zapisu trzydziestu partii (preferowane były jak najlepsze wyniki) dla każdej konfiguracji liczby graczy. Plik służący za źródło danych jest dostępny pod ścieżką *src/dataset/learn_all.csv* w repozytorium projektu.

4.7 Wyniki

Wyniki otrzymane w trakcie eksperymentu zostały zawarte w Tablicy 4.3, oraz zilustrowane na Rysunkach 4.1, 4.2 oraz 4.3.


| Cecha | 2 graczy | 3 graczy | 4 graczy | 5 graczy | ogólnie |
|------------------------|----------|----------|----------|----------|---------|
| Minimum | 55 | 37 | 27 | 15 | 15 |
| Maksimum | 163 | 178 | 159 | 180 | 180 |
| Srednia | 106,41 | 100,01 | 100,13 | 96,23 | 99,69 |
| Mediana | 107 | 100 | 101 | 98 | 101 |
| (%) > 110 | 38,07 | 38,27 | 24,79 | 21,12 | 25,71 |
| (%) > 120 | 14,81 | 10,24 | 10,12 | 7,54 | 9,92 |
| (%) > 140 | 2,26 | 0,55 | 1,14 | 0,79 | 1,05 |
| Zrealizowane bilety | 3,91 | 3,55 | 3,70 | 3,31 | 3,56 |
| Niezrealizowane bilety | 0,28 | 0,43 | 0,38 | 0,37 | 0,37 |
| Ruchy zabronione | 7 | 9 | 8 | 22 | 46 |

Tablica 4.3: Wyniki uzależnione od ilości graczy

4.8 Podsumowanie

Wyniki otrzymane w części dotyczącej sieci neuronowych wskazują, że proces uczenia miał swoje słabsze i mocniejsze strony. Analogicznie do modelu algorytmicznego wraz z wzrostem ilości graczy model radził sobie coraz gorzej. Widać to zwłaszcza w mierniku *Ruchy zabronione*, który oznacza, że sieć wskazała decyzję, która w danej turze była niemożliwa do zrealizowania. Najwięcej takich sytuacji zaszło w przypadku rozgrywek dla 5 graczy.

W porównaniu do algorytmu, sieć radzi sobie znacznie lepiej w rozgrywkach od trzech do



Rysunek 4.1: Rozkład punktacji wg. ilości graczy

pięciu graczy jednocześnie nieznacznie tracąc w rozgrywkach dwuosobowych. Należy zaznaczyć, że średnia jest wyższa o 1,5 punktu zwycięstwa podczas gdy mediana aż o 2 punkty. Lepsza średnia jednocześnie została poniesiona kosztem rozgrywek o bardzo dobrym wyniku. Porównując Rysunki 4.2 oraz 3.4 można zauważyć, że w przypadku rezultatów rozgrywek sieci neuronowej rozkład jest bardziej śpiczasty, bardzo szybko rośnie częstość danego wyniku do maximum ok. 107 punktów. Następnie znacznie w porównaniu do modelu algorytmicznego szybciej spada.

Kolejną zauważalną analogią są bardzo zbliżone do siebie wyniki rozgrywek trzy oraz czterosobowych. W analizie konfiguracji trend malejącej średniej oraz mediany się utrzymuje względem modelu algorytmicznego. Może zaskoczyć natomiast, że największe wyniki otrzymywane były w rozgrywkach 3 oraz 5 osobowych co możemy zaobserwować na Rysunku 4.3.

Na Rysunku 4.1 możemy natomiast zauważyć przebieg rozkładu punktów w zależności ilości graczy. Dla rozgrywek pięciograczowych wykres zaczyna rosnąć najwcześniej, w okolicach 62 punktów zwycięstwa. Dla rozgrywek dla dwóch graczy wyniki zaczynają się częściej pojawiać dopiero od poziomu 83 punktów, i jednocześnie najbardziej się wybijają. Z dwóch pozostałych konfiguracji, ta dla czterech graczy ma bardziej ostry przebieg.

Ostatnią cechą rozgrywki, którą możemy ocenić na podstawie otrzymanych wyników jest średnia liczba zrealizowanych biletów - wyższy wynik oznacza lepsze poprowadzenie rozgrywki, oraz liczbę biletów, których nie udało się zrealizować. Pierwsza z tych metryk jest wyższa w przypadku modelu wykorzystującego sieci neuronowe aż o 0,5 bileta na gracza. Oznacza to, że przeciętnie gracz grał bardziej odważnie. Druga z metryk dotyczących biletów



Rysunek 4.2: Globalny rozkład punktów


jest natomiast niższa w tym modelu aż o 0,2 bileta.

4.9 Wnioski na temat uczenia

Zgodnie z podstawami uczenia maszynowego - dużo zależy od tego jaki jest model danych uczących oraz jakie jakościowo dane dostarczone są do sieci, którą chcemy nauczyć podejmować decyzje. Ograniczenia, jakie pojawiają się w przypadku zbioru danych uczących oraz słabości samych danych odbijają się na działaniu sztucznej sieci neuronowej.

Lepsze średnie wyniki w symulacjach z wykorzystaniem sieci neuronowych są spowodowane tym, że jako źródło danych do zbioru uczącego wykorzystano zapisy partii z najwyższą zdobyczą punktową. Starano się by wyniku tych partii osiągnięto wynik końcowy co najmniej 130 punktów zwycięstwa. Taki sposób zebrania danych uczących pozwolił jednocześnie zachować schematy działania z oryginalnego algorytmu co zaskutkowało wymagającą w kontekście konfrontacji zdobyczą punktową, jak i niosło skutek w postaci swobody w przypadku sytuacji niejednoznacznych.

Pomimo uzyskania wyższego średniego wyniku punkowego względem modelu algorytmicznego proces uczenia mógł odnieść lepsze rezultaty. Przykładowo, nie udało się doprowadzić, żeby w trakcie całej symulacji nie zostały podjęte decyzje klasyfikowane jako zabronione.



Rysunek 4.3: Wyniki wg. ilości graczy

Rozdział 5

Optymalizacja wyników

5.1 Wprowadzenie do eksperymentu

Sztuczna inteligencja powinna w swoim działaniu dążyć do jak najlepszych wyników. W przypadku sztucznej sieci neuronowej najlepsze wyniki uzyskujemy poprzez dobór odpowiednich modeli / zbioru danych uczących. Sam dobór oraz wykorzystanie danych może się różnić w zależności od rozważanej sytuacji. W przypadku sztucznej inteligencji dla rozważanej gry możemy zastosować następujące podejścia:

1. Przygotować specjalny model dla każdej konfiguracji liczby graczy, każdy model ma swój zbiór danych uczących. Model zbudowany za pomocą danego zbioru rozgrywek zostanie wykorzystany jedynie w przypadku gier o takiej samej liczbie graczy. W dalszej części pracy nazwany **model specyficzny**
2. Przygotować wspólny zbiór danych uczących z danych wykorzystanych w poprzednim podpunkcie. W trakcie symulacji model wykorzystujemy w każdej rozgrywce - niezależnie od ilości uczestniczących graczy. W dalszej części pracy nazwany **model uniwersalny**

W trakcie tej części swojej pracy chcę zbadać, który z wspomnianych modeli zapewni lepszy wynik punktowy w trakcie symulacji.

5.2 Przebieg doświadczenia

Na początku przygotowałem zbiory danych uczących dla każdej konfiguracji liczby graczy, jako klucz wybierając rozgrywki według najlepszego wyniku końcowego. Zbiór danych dla każdej konfiguracji liczby graczy składał się z zapisu decyzji trzydziestu rozgrywek. Dodatkowo na końcu wszystkie zbiory danych uczących zapisane zostały do dodatkowego pliku, który następnie zostanie wykorzystany do budowy modelu *uniwersalnego*.

Po przygotowaniu zbiorów danych uczących uruchomione zostało doświadczenie. Na początku przeprowadzenie uczenia sieci - 40 epok z rozmiarem batch'a wynoszącym 250 decyzji gracza.

Dla każdej konfiguracji przeprowadzono po 60 rozgrywek - oddzielnie dla modelu uniwersalnego oraz modelu specyficznego. W sumie dla tej części przeprowadzono 480 gier testowych, których wyniki zamieszczono poniżej.

5.3 Wyniki

Wyniki otrzymane w doświadczeniu zostały zawarte w Tablicach 5.1 oraz 5.2 oraz omówione w następnej sekcji.

| Cecha | 2 graczy | 3 graczy | 4 graczy | 5 graczy | ogólnie |
|------------------------|----------|----------|----------|----------|---------|
| Minimum | 41 | 48 | 46 | 41 | 41 |
| Maksimum | 157 | 140 | 148 | 142 | 157 |
| Srednia | 101,66 | 99,4 | 97,36 | 92,05 | 96,57 |
| Mediana | 99,5 | 101 | 100 | 91 | 97 |
| Ukończonych rozgrywek | 60 | 55 | 60 | 56 | 231 |
| (%) > 110 | 28,33 | 24,24 | 25,00 | 18,57 | 23,11 |
| (%) > 120 | 18,33 | 10,30 | 8,75 | 8,21 | 10,31 |
| (%) > 140 | 4,17 | 0,00 | 0,42 | 0,36 | 0,87 |
| Zrealizowane bilety | 467 | 575 | 873 | 951 | 2866 |
| Niezrealizowane bilety | 63 | 66 | 102 | 135 | 366 |

Tablica 5.1: Podsumowanie - modele operujące na precyzyjnych danych uczących

| Cecha | 2 graczy | 3 graczy | 4 graczy | 5 graczy | ogólnie |
|------------------------|----------|----------|----------|----------|---------|
| Minimum | 45 | 49 | 54 | 37 | 37 |
| Maksimum | 154 | 133 | 144 | 143 | 154 |
| Srednia | 108,12 | 96,51 | 97,69 | 94,88 | 98,00 |
| Mediana | 108 | 97 | 99,5 | 96,5 | 99 |
| Ukończonych rozgrywek | 60 | 60 | 59 | 56 | 235 |
| (%) > 110 | 43,33 | 24,44 | 23,73 | 21,07 | 25,86 |
| (%) > 120 | 25,00 | 7,78 | 8,05 | 7,14 | 10,17 |
| (%) > 140 | 3,33 | 0,00 | 1,27 | 0,71 | 1,10 |
| Zrealizowane bilety | 515 | 603 | 855 | 939 | 2912 |
| Niezrealizowane bilety | 41 | 90 | 83 | 111 | 325 |

Tablica 5.2: Podsumowanie - modele operujące na uniwersalnych danych uczących

5.4 Omówienie wyników

Cieężko wskazać, które z dwóch sprawdzanych podejść gwarantuje lepsze rezultaty. Za kluczowe wskaźniki można uznać średni wynik oraz medianę punktów, które są wyższe w przy-

padku modelu uniwersalnego. Dodatkowo bardziej korzystna jest ilość dokonanych ruchów zabronionych, mniej ruchów w przypadku modelu uniwersalnego. Na korzyść tego modelu jest również w przypadku każdej liczby graczy uczestniczących w rozgrywce procentowa ilość graczy, którzy przekroczyli wskazaną ilość punktów. Z drugiej strony model specyficzny ma wyższy najniższy wynik oraz wyższy najwyższy wynik.

Do ciekawszych wniosków prowadzą wyniki poszczególnych konfiguracji liczby graczy. Dla dwóch graczy uniwersalny model danych uczących (również wspólny model sieci) w trakcie symulacji osiąga znacząco lepsze rezultaty. Oczekiwana wartość punktowa jest wyższa w tym przypadku aż o 7 punktów, a w dodatku procentowy udział graczy z uzyskaną liczbą punktów wyższą od 110 punktów jest wyższy o 15 punktów procentowych. W tym modelu aż 43,33% wszystkich graczy osiąga co najmniej 110 punktów, a 25% zdobywa co najmniej 10 punktów więcej. W przypadku tej konfiguracji, wykorzystanie modelu uniwersalnego zapewni graczowi znacznie bardziej wymagającego przeciwnika.

Rekomendacja: Model uniwersalny

Sytuację, w której model precyzyjny osiąga lepsze rezultaty można zauważyć już w konfiguracji dla trzech graczy. Średnia zdobycz punktowa jest w tym przypadku lepsza o 3 punkty, a mediana aż o 4 punkty. Na korzyść modelu uniwersalnego działa natomiast ilość rozgrywek rozegranych bez wykonania ruchu zabronionego. Kluczowa dla wyboru rekomendacji jest średni oraz najwyższy wynik punktowy, mając na uwadze niebezpieczeństwo, że gracz zagra niezgodnie z zasadami gry.

Rekomendacja: Model precyzyjny

Dla kolejnej z konfiguracji możemy zauważyć zbliżone do siebie wyniki. Zarówno średnia jak i mediana wyników są bardzo zbliżone do siebie - 97,36 oraz 97,69. Procentowy udział wyników rozgrywek z wynikiem powyżej 140 punktów jest lepszy dla uniwersalnych danych uczących. Dla zwiększenia prawdopodobieństwa uzyskania wyniku powyżej 110 oraz 120 punktów należało wykorzystać model precyzyjny. Model uniwersalny w przypadku tej serii symulacji nie ukończył wszystkich rozgrywek. Ważnym czynnikiem w przypadku decyzji, które z podejść jest lepsze w tym przypadku jest liczba gier z zadowalającym wynikiem. Na korzyść przemawia model precyzyjny, dla którego jeden na czterech graczy zakończy rozgrywkę z 110 punktami lub więcej.

Rekomendacja: model precyzyjny

Ostatnią konfiguracją jest rozgrywka dla pięciu graczy. W tym przypadku lepsze wyniki osiągnęte są w przypadku modelu wyuczonego na uniwersalnych danych. Oczekiwana oraz mediana wyniku są wyższe o odpowiednio 2,83 oraz 5,5 punktów. Procentowy udział rozgrywek z wynikiem 110 oraz 140 punktów również działa na korzyść omawianego modelu. Dodatkowo, znacznie niższa jest liczba niezrealizowanych biletów.

Rekomendacja: model uniwersalny

5.5 Podsumowanie



Rysunek 5.1: Zakres punktów dla badanych modeli

Podsumowując aktualny rozdział nie można jednoznacznie określić, z którego z tych dwóch modeli lepiej będzie skorzystać. Najlepiej będzie wykorzystać system mieszany, który adaptowalny byłby dla danej sytuacji. Dla rozgrywek dwu i pięciu osobowych wykorzystać model uniwersalny, dla pozostałych - model precyzyjny. Jako przyczynę przewagi w uogólnieniu - modelu uniwersalnego - można wskazać większą ilość różnych zdarzeń w trakcie rozgrywki. Dla graczy grających zgodnie z algorytmem dla konkretnej konfiguracji gry zakres zdarzeń z modelu uczącego będzie ograniczony, a od pewnej ilości epok w procesie uczenia, mogą się powtarzać konkretne decyzje. Duże znaczenie dla przeprowadzenia symulacji ma również specyfika danej konfiguracji. Na przykład w rozgrywkach trójosobowych znacznie szybciej zapełnia się plansza w porównaniu do rozgrywek dwuosobowych, więc rozgrywka musi być przeprowadzona szybciej. W przypadku rozgrywek 3 i 4 osobowych wykorzystanie modelu precyzyjnego będzie ograniczało możliwość popełnienia ruchu nieoptymalnego. W przypadku rozgrywek 2 i 5 osobowych, model uniwersalny zapewni szersze spektrum działań i możliwych taktyk. Wyniki osiągane przy pomocy modelu uniwersalnego zawierają się w szerszym zakresie zdobyczy punktowej co jest widoczne na Rysunku 5.1.

Rozdział 6

Dowód działania sieci

6.1 Wprowadzenie do eksperymentu

Poza wskazaniem, że wyniki osiągane przez sieć neuronową są zbliżone do tych osiąganych przez algorytm należy udowodnić, że przygotowany model oraz założenia, jakimi się kierowałem przy projektowaniu sieci neuronowej są słuszne. W tym celu określono metryki za pomocą których można opisać wyniki pracy sieci. Należy wskazać przede wszystkim, że wyniki osiągane w rozgrywkach sterowanych przez *Losową* sieć neuronową są średnio gorsze od osiąganych przez *wyuczoną* sieć neuronową.

6.2 Model eksperymentu

W celu udowodnienia działania modelu sieci neuronowej przeprowadziłem eksperyment w formie ewaluacji modelu w trakcie procesu uczenia sieci. Dla każdej epoki składającej się z uczenia za pomocą próbki zawierającej pięćset *zapisów decyzji* przeprowadziłem ewaluację modelu dla losowych 100 wpisów z zbioru uczącego a następnie rozgrywałem sześćdziesiąt partii w każdej konfiguracji (od dwóch do pięciu graczy) liczby graczy co w sumie daje wynik 240 rozgrywek na iterację.


6.3 Wyniki

Wyniki otrzymane w trakcie doświadczenia umieszczono w Tablicy 6.1.

6.4 Podsumowanie

W dowodzie pojawia się trudność w ocenie postępów uczenia, gdyż rozważany problem nie jest trywialny i realna możliwość oceny sztucznej inteligencji pojawia się dopiero po rozegraniu całej partii trwającej średnio ok. 40 tur.

Najprostszym wyznacznikiem jest średnia zdobycz punktowa, która dla losowej konfiguracji nie skutkowałą żadną rozegraną do końca rozgrywką. W każdej z 240 gier, jeden z graczy



Rysunek 6.1: Rozkład punktacji w procesie uczenia

dokonał ruchu zabronionego. Dostyc szybko, gdyż po zaledwie jednej epoce gracz komputerowy wykorzystujący uczoną sieć neuronową i za jej pomocą wyznaczający swoje posunięcia był w stanie rozegrać partię do końca. Na 240 gier zaledwie jedna zakończyła się podjęciem decyzji zabronionej. Niestety oczekiwany wynik uzyskiwany przez tą sieć był względnie niski. Dla modelu algorytmicznego oczekiwana wynosiła 98,16 (W nawiązaniu do Tablicy 3.1), w tym przypadku wynik był aż o ok. 17 punktów niższy i wynosił 81,63 punkta. Niskie wartości miały również najniższy osiągnięty wynik (wartość ujemna spowodowana nieukończonymi biletami) jak i najwyższy wynik w całej serii rozgrywek.

Nie można wskazać dominującego trendu w dalszym procesie uczenia. Do szóstej iteracji procesu uczenia (próbka danych uczących - 600) średnia wartość wyników gracza reguranie wzrastała. Od piątej epoki oczekiwany wynik wynosił ok. 95 punktów, co można uznać za akceptowalny wynik w kontekście zbioru uczącego.

W trakcie procesu uczenia wzrastał natomiast najniższy osiągany wynik przez wszystkich graczy w wszystkich seriach testu. Natomiast wynik najwyższy utrzymywał się w granicach 150-160 punktów, który to wynik sprawiłby trudność doświadczonemu graczowi.

Dodatkowo, na podstawie rysunku 6.1 można zauważyć trend - rosnąca średnia wartość zdobyczy punktowej wraz z malejącą wartością średniej straty (parametr average loss). Na wykresie można dostrzec również powolną stabilizację najwyższego oraz najniższego wyniku, jaki osiągnęła sieć w trakcie symulacji gier.

| | | | | | |
|---|-------|-------|-------|-------|-------|
| Aktualna iteracja | 0 | 1 | 2 | 3 | 4 |
| Sumaryczna ilość danych uczących | 0 | 100 | 200 | 300 | 400 |
| Srednie odchylenie od próbki | 7.614 | 0.649 | 0.490 | 0.610 | 0.333 |
| Srednia pewnosc klasyfikacji | 0.107 | 0.689 | 0.800 | 0.692 | 0.885 |
| Liczba gier zakończonych przerwaniem (ruchem zabronionym) | 240 | 1 | 32 | 4 | 47 |
| Maksymalna liczba punktów | - | 123 | 144 | 125 | 151 |
| Minimalna liczba punktów | - | -3 | 26 | 4 | 47 |
| Liczba graczy która ukończyła rozgrywki | 0 | 835 | 702 | 824 | 654 |
| Srednia zdobycz punktowa | - | 81.63 | 87.23 | 75.69 | 94.80 |
| Srednia liczba tur potrzebnych do zakonczenia rozgrywki | 1.70 | 40.75 | 42.23 | 39.44 | 44.25 |
| Srednia liczba ukonczonych biletów | - | 2,21 | 2,39 | 1,9 | 3,08 |
| Srednia liczba nieukonczonych biletów | - | 0,43 | 0,33 | 0,54 | 0,32 |

Tablica 6.1: Wyniki pierwszych pięciu epok uczenia

Rozdział 7

Podsumowanie pracy

Przygotowanie sztucznej inteligencji dla gry *Wsiąść do pociągu* było jednocześnie wyzywające oraz uczące. Do skutecznego działania konieczne było opracowanie algorytmów działających jednocześnie efektywnie jak i uniwersalnie. Jako cel założono uzyskanie jak najwyższego oczekiwanego wyniku z możliwością wybicia się przy odpowiednim ułożeniu kart.

Dla redukcji złożoności problemów zrezygnowano z następujących elementów:

1. Dodatkowe dziesięć punktów dla posiadacza najdłuższej ścieżki
2. Interakcje polegające na blokowaniu sobie połączeń

oraz założono, że gracz zawsze stara się grać jak najlepiej dla swojego wyniku.

Opisywana w pracy gra jest skomplikowana z dużą ilością danych, które opisać można jako losowe. Mamy do dyspozycji dwie różne talie - zasobów oraz biletów, problem grafowy oraz interakcje z innymi graczami. Trudnym zadaniem jest przygotować sztuczną inteligencję, która podejmie dobrą decyzję dla każdej decyzji, nawet tej najbardziej niszowej oraz nieprzewidywalnej.

Otrzymane wyniki dowiodły, że zaproponowany algorytm może być wykorzystywany w trakcie rozgrywek oraz może posłużyć jako schemat działania, który można wykorzystać w własnych rozgrywkach.

Rozdział 8

Słownik

Gracz Uczestnik rozgrywki - sterowany przez sztuczną inteligencję. Przygotowano poniższych uczestników

Model algorytmiczny Sztuczna inteligencja działająca w oparciu o algorytm. Wykorzystany do uzyskania danych uczących

Sieć neuronowa Sztuczna sieć neuronowa - klasyfikuje rodzaj decyzji jaka ma zostać podjęta przez gracza

Decyzja Podejmowana przez uczestnika rozgrywki decyzja (rezerwacja połączenia, pobranie kart wagonów lub pobranie kart biletów)

Decyzja zabroniona Podjęta przez gracza decyzja niemożliwa w danym momencie z punktu widzenia gry. *Przykładowo brakujące zasoby gry*

Bilet Losowane przez uczestnika rozgrywki zadanie do zrealizowania. Określony przez dwa miasta, które gracz musi ze sobą połączyć (za pomocą zarezerwowanych połączeń). W przypadku udanego zrealizowania zadania gracz zdobywa określoną liczbę punktów. W przeciwnym przypadku punkty są odejmowane z zdobytej puli.

Połączenie Połączenie dwóch sąsiadujących ze sobą miast. Połączenia charakteryzują się ilością nitek (1 lub dwie), kolorystyką (jeden z 8 kolorów lub połączenie bezbarwne) oraz długością. Można zbudować graf wykorzystując miasta jako węzły oraz połączenia jako krawędzie.

Sciezka/nitka/tor Jest to najmniejszy element połączenia zajmowany wyłącznie przez jednego z graczy. Jest opisywany przez indywidualny kolor. Jest przypisany do jednego połączenia, a jedno połączenie może mieć jeden (zwykłe połączenie) lub dwa (połączenie podwójne) tory.

Wagon Element (w fizycznej wersji gry) służący do znakowania zarezerwowanych połączeń. Jeden wagonik odpowiada jednej karcie wagonów służącej do zarezerwowania połączenia. Gracz na początku posiada 45 wagonów. W momencie, gdy jeden z graczy ma 2 wagony lub mniej gracze wykonują jeszcze po jednym ruchu po czym przechodzą do fazy podliczenia punktów na koniec rozgrywki.

Karta wagonu Element rozgrywki. W grze występuje jako jeden z 8 zasobów (kolorów) - po 10 sztuk, oraz karta joker (zastępuje dowolną kartę zasobów) - w ilości 12 sztuk. Gracz wykorzystuje karty zasobów do zrealizowania połączenia.

Stan gry Stan rozgrywki składający się z informacji o planszy (w tym kolejność ułożenia niewidocznych kart) oraz informacji o graczach. Stan gry jest przedstawiony w sposób redundantny - np. wagony przedstawione są jako licznik, a kolor gracza nie ma znaczenia - jedynie jego identyfikator.

Punkt (zwycięstwa) Jest to wynik gracza. Punkt zwycięstwa zdobywa się za realizację biletów oraz rezerwacje połączeń między miastami.

Rozdział 9

Bibliografia

1. Instrukcja do gry

Dostęp: 02 września 2018

https://www.wydawnictworebel.pl/repository/files/instrukcje/WdP_USA.pdf

2. Omówienie botów do gry - forum Board Game Geek

Dostęp: 02 września 2018

<https://boardgamegeek.com/thread/1523665/ai-project-solo-multiplayer-games>

3. Repozytorium projektu

Dostęp: 2 września 2018

<https://github.com/paqaos/msc-ticket-to-ride-nn-ai>

4. Wprowadzenie do algorytmów (Introduction to Algorithms)

Cormen, Thomas H., Leiserson, Charles E., Rivest, Ronald L.

1997, Wydawnictwa Naukowo-Techniczne, Warszawa

Spis rysunków

| | | |
|-----|---|----|
| 3.1 | Schemat blokowy algorytmu podejmującego decyzje o typie wykonywanego ruchu | 12 |
| 3.2 | Schemat blokowy algorytmu podejmującego decyzje o wyborze najlepszego podzbioru biletów | 13 |
| 3.3 | Rozkład punktacji wg. ilości graczy | 15 |
| 3.4 | Globalny rozkład punktów | 16 |
| 3.5 | Wyniki wg. ilości graczy | 16 |
| 4.1 | Rozkład punktacji wg. ilości graczy | 22 |
| 4.2 | Globalny rozkład punktów | 23 |
| 4.3 | Wyniki wg. ilości graczy | 24 |
| 5.1 | Zakres punktów dla badanych modeli | 28 |
| 6.1 | Rozkład punktacji w procesie uczenia | 30 |

Spis tablic

| | | |
|-----|--|----|
| 1.1 | Ilość punktów otrzymywanych za zrealizowanie połączenia | 6 |
| 2.1 | Parametry rozgrywki | 9 |
| 2.2 | Konfiguracja danych testowych | 9 |
| 3.1 | Wyniki uzależnione od ilości graczy | 15 |
| 4.1 | Dane wejściowe sieci neuronowej | 20 |
| 4.2 | Klasy określone przez klasyfikator | 20 |
| 4.3 | Wyniki uzależnione od ilości graczy | 21 |
| 5.1 | Podsumowanie - modele operujące na precyzyjnych danych uczących | 26 |
| 5.2 | Podsumowanie - modele operujące na uniwersalnych danych uczących | 26 |
| 6.1 | Wyniki pierwszych pięciu epok uczenia | 31 |